

<http://www.mojvideo.com/video-a-i-artificial-intelligence-2001-full-movie-online-eng-sub-1-2/de6ed4ec9390a29384a6>

????

Prednáška # 5

Umelé Neuronové siete - základy

Štruktúra prednášky

- Biologická inšpirácia
- topológia neurónových sietí
- Kontrolované verzus – nekontrolované učenie NS
- Príznakový priestor a jeho formy ako vstup do NS
- Výstup neurónovej siete a jeho formy
- Perceptron ako jednoduchá neurónová sieť
- Metoda spätného šírenia chyby – základný princíp
- Univerzálna aproximačná teoréma
- Deep Learning ako komplex neurónových podsietí
- Aplikačný potencial neurónových sietí – kedy ich použiť

Motor cortex is involved in conscious thought and controls the voluntary movement of body parts

Somatosensory cortex receives and processes sensory signals from the body





Photo: Manfred Kage/Peter Arnold

Biologický neuron




Zaujímavosti o mozgu


- Mozog obsahuje približne **100 miliárd mozgových buniek** (neurónov)
- Počas skorých fáz tehotenstva vzniká aj **250 000 neurónov za jedinú minútu**
- Viac neurónov je **na ľavej strane** mozgu (cca o 186 miliónov)
- Celková rozloha mozgovej kôry je **2500 cm štvorcových**
- 77 – 78 percent mozgu tvorí **voda**
- Asi **4 minúty bez kyslíka** vydrží mozog bez vážnejších dôsledkov
- Mozgová hmota v sebe **nemá receptory bolesti**, mozog teda nemôže cítiť bolesť
- Mozog dokáže spracovať informácie rýchlosťou **120 metrov za sekundu**
- Keď človek bdie, jeho mozog produkuje medzi **10 a 23 wattmi energie**
- **Prostredie**, v ktorom dieťa vyrastá, má vplyv na výkon mozgu (plus mínus 25 percent) - pomáha napríklad aj čítanie nahlas

Topológia neurónových sietí

Dopredná NS



Rekurentná NS




Toky signálu v rámci neurónovej siete

1. Sekvenčný
2. Blok Sekvenčný
3. Synchronny
4. Asynchronny


Čo je to SPIKE – forma šírenia signálu v mozgu

Integrate & Fire



Čo sú to neurónové siete ?

Neurón - procesný element






Vstupná funkcia


- **SIGMA Neuron**
- **PI – NEURON**
- **Mix typ**

Aktivačná funkcia


1. Linearna funkcia
2. Po častiach lineárna
3. Sigmoidalna funkcia
4. iné



Iné aktivačné funkcie napr. Gaussian ...



Výstupná funcia



Funkcia Identity
—
alebo iná funkcia

Aká je vhodná funkcia ?????

- závisí od topológie
- závisí od dát
- závisí od spôsobu učenia

Čo vraví biológia ??? – Aké aktivačné funcie má biologický neurón?




Základná logika učenia Neurónových sietí

Dáta :



Učenie – Kontrolované učenie – Máme vstupy do systému a k nemu prislúchajúce výstupy

Učenie – Nekontrolované - máme iba vstupy

Čo robí mozog ?



OR






Základná logika učenia Neurónových sietí

Dáta :



Učenie – Kontrolované učenie – Máme vstupy do systému a k nemu prislúchajúce výstupy

Učenie – Nekontrolované - máme iba vstupy

Čo robí mozog - kontrolovanom prístupe ???



OR



Chyba E



Kontrolované učenie

Chyba Učenia $E \rightarrow 0$ Ako a čím to dosiahnuť

Zmena Váh NS

Teda :

Učenie NS je $\delta E / d w \neq 0$ - proces učenia

Život NS je $\delta E / d w = 0$ - proces života

Aká chyba ????

1. Chyba prvého typu - Ozaj je to MALE a klasifikuje to ako FEMALE

2. Chyba druhého typu – NAOZAJ je to FEMALE a klasifikuje to ako MALE

	MUŽ	ŽENA	
Výstup 1	88	6	
Výstup 2	12	94	

Kvantitatívna forma hodnotenia CHYBY

1. Jednoduchá – odchýlka od chyby na výstupe NS
obecne – tzv. Akumulovaná Chyba
2. Komplexná – kontigenčná tabuľka

Chybová Tabuľka

Image To Be Evaluated							
Reference		Urban	Agriculture	Range	Forest	Water	
	Urban	310	9	18	23	18	378
	Agriculture	61	1051	92	147	12	1363
	Range	12	32	561	86	17	708
	Forest	23	87	218	1202	8	1538
	Water	11	7	12	27	270	327
		417	1186	901	1485	325	3394

Dalšie informácie o mozgu ...

<http://magazin.atlas.sk/zdravie/10-naj-prekvapivych-pravd-o-mozgu/807349.html>




https://www.youtube.com/watch?v=gck_5x2KsLA



QUESTION :



"Viete si predstavit klasifikaciju že na vstupe je politik a na výstupe do ake strany patrí ???

Čo robí mozog - nekontrolovanom prístupe ???



OR

Rozdiel



Ne-existuje učiteľ



Existuje niečo medzi kontrolovaným a nekontrolovaným učením


<https://www.youtube.com/watch?v=GPAfjWsKmmQ>

Vstup do Neurónovej siete – príznakový priestor – Dáta

1. Realne Data (v prípade obrazu napr. pixely z RGB obrazu)
2. Odvodené dáta – tzv. Descriptory...
(v prípade obrazu – texturalne a contexturalne príznaky)



Čo je to digitálny obraz ?

Electromagnetic Spectrum



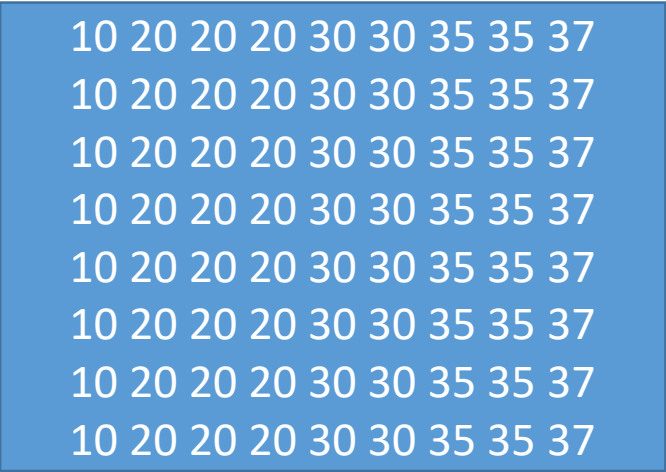
Colorimetria

R B G ...





Čo je to digitálny obraz ...



10	20	20	20	30	30	35	35	37	
10	20	20	20	30	30	35	35	37	
10	20	20	20	30	30	35	35	37	
10	20	20	20	30	30	35	35	37	
10	20	20	20	30	30	35	35	37	
10	20	20	20	30	30	35	35	37	
10	20	20	20	30	30	35	35	37	
10	20	20	20	30	30	35	35	37	

Pseudo Farby

	R	G	B
10	50	80	100
20	10	0	255
37	255	255	255

Rozmery digitálneho obrazu


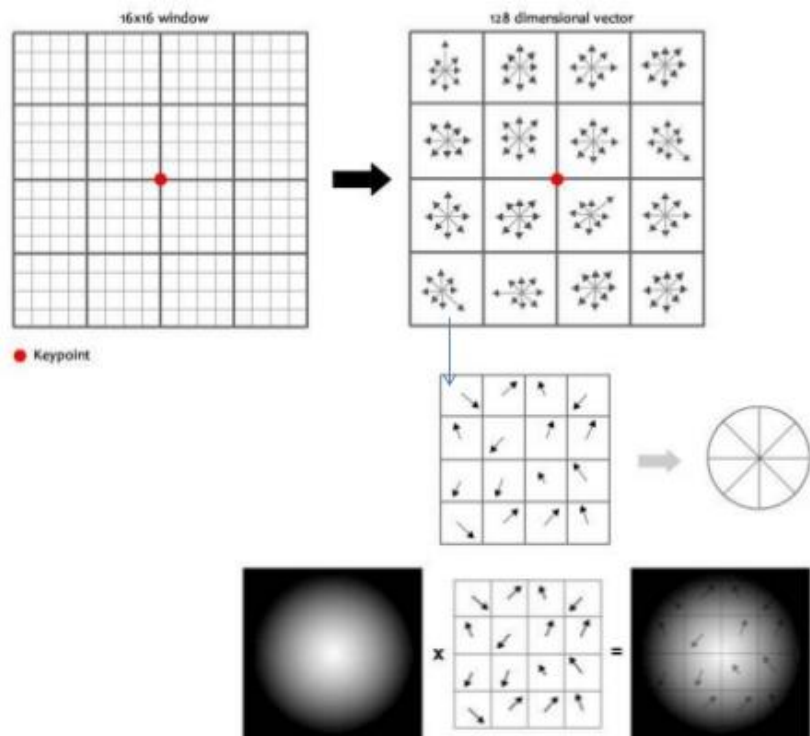


n x m (RBG)

1. 640 x 480
2. HD 1440 x 1080
3. Full HD 1920x 1080
4. UHD image 3840 x 2160
5. Cinema 4K image 4096 x 3112
6. 8K image 7680 x 4320

Odvozené příznaky

Generate SIFT features



Koniec časti čo je to digitálny obraz

Čo je výstup Neurónovej siete


Napr. : trieda – výsledok klasifikácie

Rôzne formy

- 1. Priama**
- 2. Kodovaná**

Perceptron – základná neurónová sieť

Perceptron (1957)




Frank Rosenblatt
(1928-1971)

Original Perceptron

(From Perceptrons by M. L. Minsky and S. Papert, 1969, Cambridge, MA: MIT Press. Copyright 1969 by MIT Press.)

Simplified model:




Perceptron ... Lineárna klasifikácia

https://www.youtube.com/watch?v=cNxadbrN_al

Teda o čo ide pri perceptrone – aká je úloha ??


ČO vieme : (apriorna informácia)

Máme iba dve triedy – FEMALE and MALE
Iná trieda NEMOŽE BYŤ

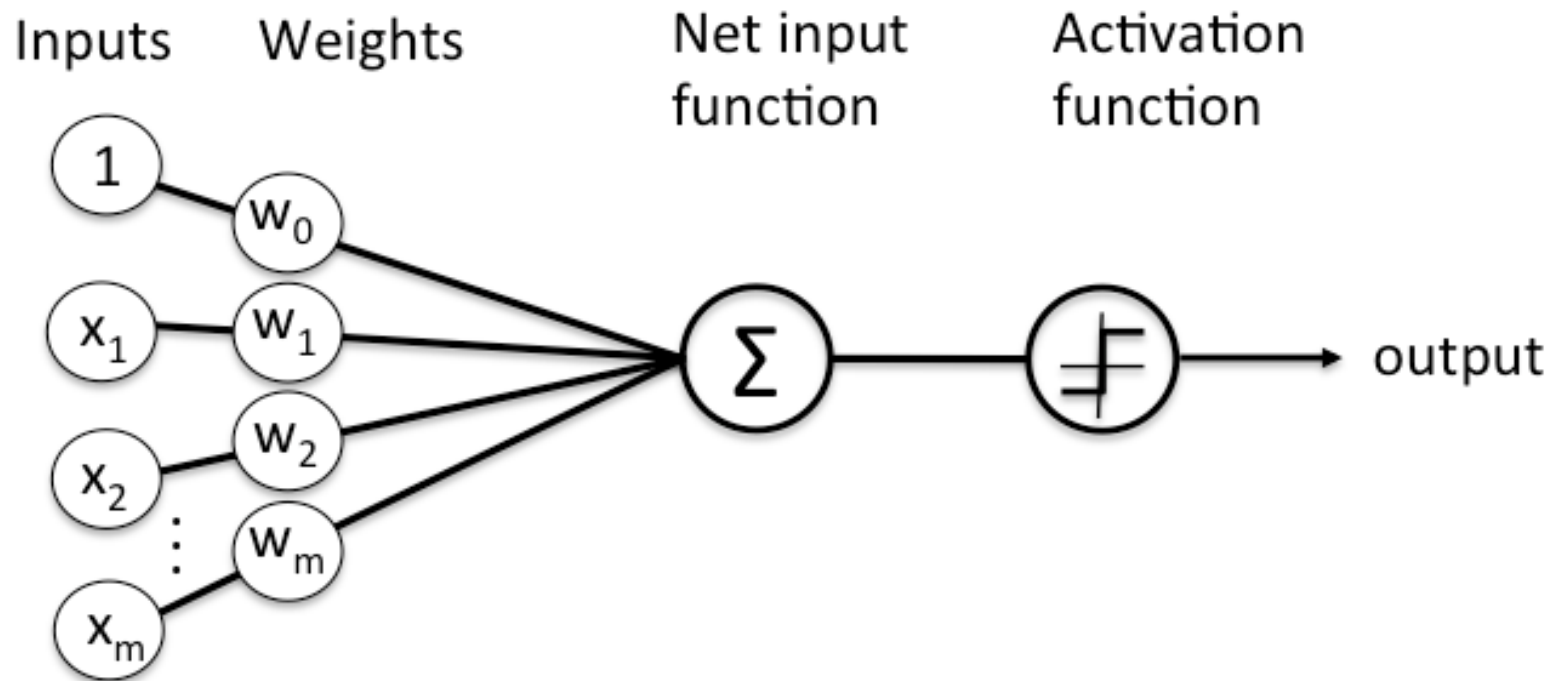


Chceme stroj ktorý sa naučí
rozdeľovať mužov a ženy do
dvoch tried

Teda ide o rozdelenie príznakového priestoru



Ako meniť tieto váhy ???



Schematic of Rosenblatt's perceptron.

Pravidla adaptácie váh

Dva prípady

Prvý :

- A. Ak na vstupe je $X1$ (MUZ) a $\sum W. X > 0$ - tak perceptron pracuje dobre nerobím NIC
- B. Ak na vstupe je $X2$ (ZENA) a $\sum W. X \leq 0$ - tak perceptron pracuje dobre nerobím NIC

Pravidla adaptácie váh

Druhý :

A. Ak na vstupe je X_1 (MUZ) a $\sum W \cdot X \leq 0$ - tak perceptron adaptuje váhy

$$W(T+1) = W(T) + X_1$$

B. Ak na vstupe je X_2 (ZENA) a $\sum W \cdot X > 0$ - tak perceptron adaptuje váhy

$$W(T+1) = W(T) - X_2$$

Čo vlastne pri učení robim

Hľadám rovnicu separačnej priamky

<https://goo.gl/7Kqo9X> - percetron

<https://goo.gl/V6Jp0u> - Tensorflow playground

Kultúra programovania

<http://cs.stanford.edu/people/karpathy/convnetjs/started.html>



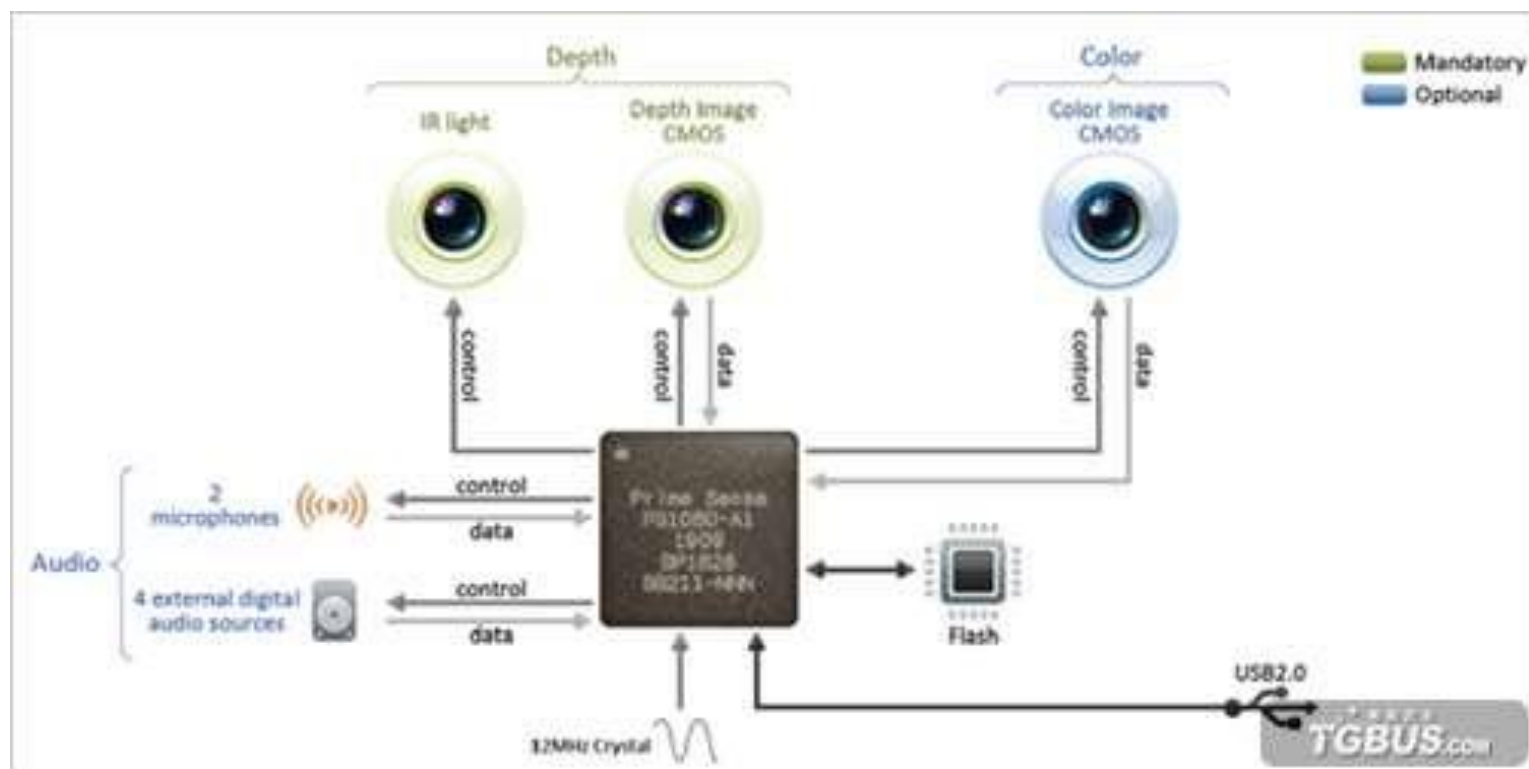
QUESTION :

"Čo je to Kinect ???

Kinect



Kinect – princíp



Konvergenčná teoréma perceptronu

Predpoklady :

Ak má N rozmerný príznakový priestor kde sú iba dve triedy, ktoré sú LINEÁRNE SEPAROVATEĽNÉ



Potom po **K – OMYLOCH**, kde K je konečné číslo budem vedieť vytvoriť „stroj“, ktorý bude spoľahlivo separovať jednu triedu od druhej – t.z. Perceptron Konverguje

Dôsledok konvergenencie


**Ak Perceptron konverguje na
N rozmerných
dátach – triedy su LINEÁRNE SEPARABILNE**

Samoštúdium o perceptrone ...


<https://www.youtube.com/watch?v=bxe2T-V8XR8>

<https://www.youtube.com/watch?v=1XkjVI-j8MM>

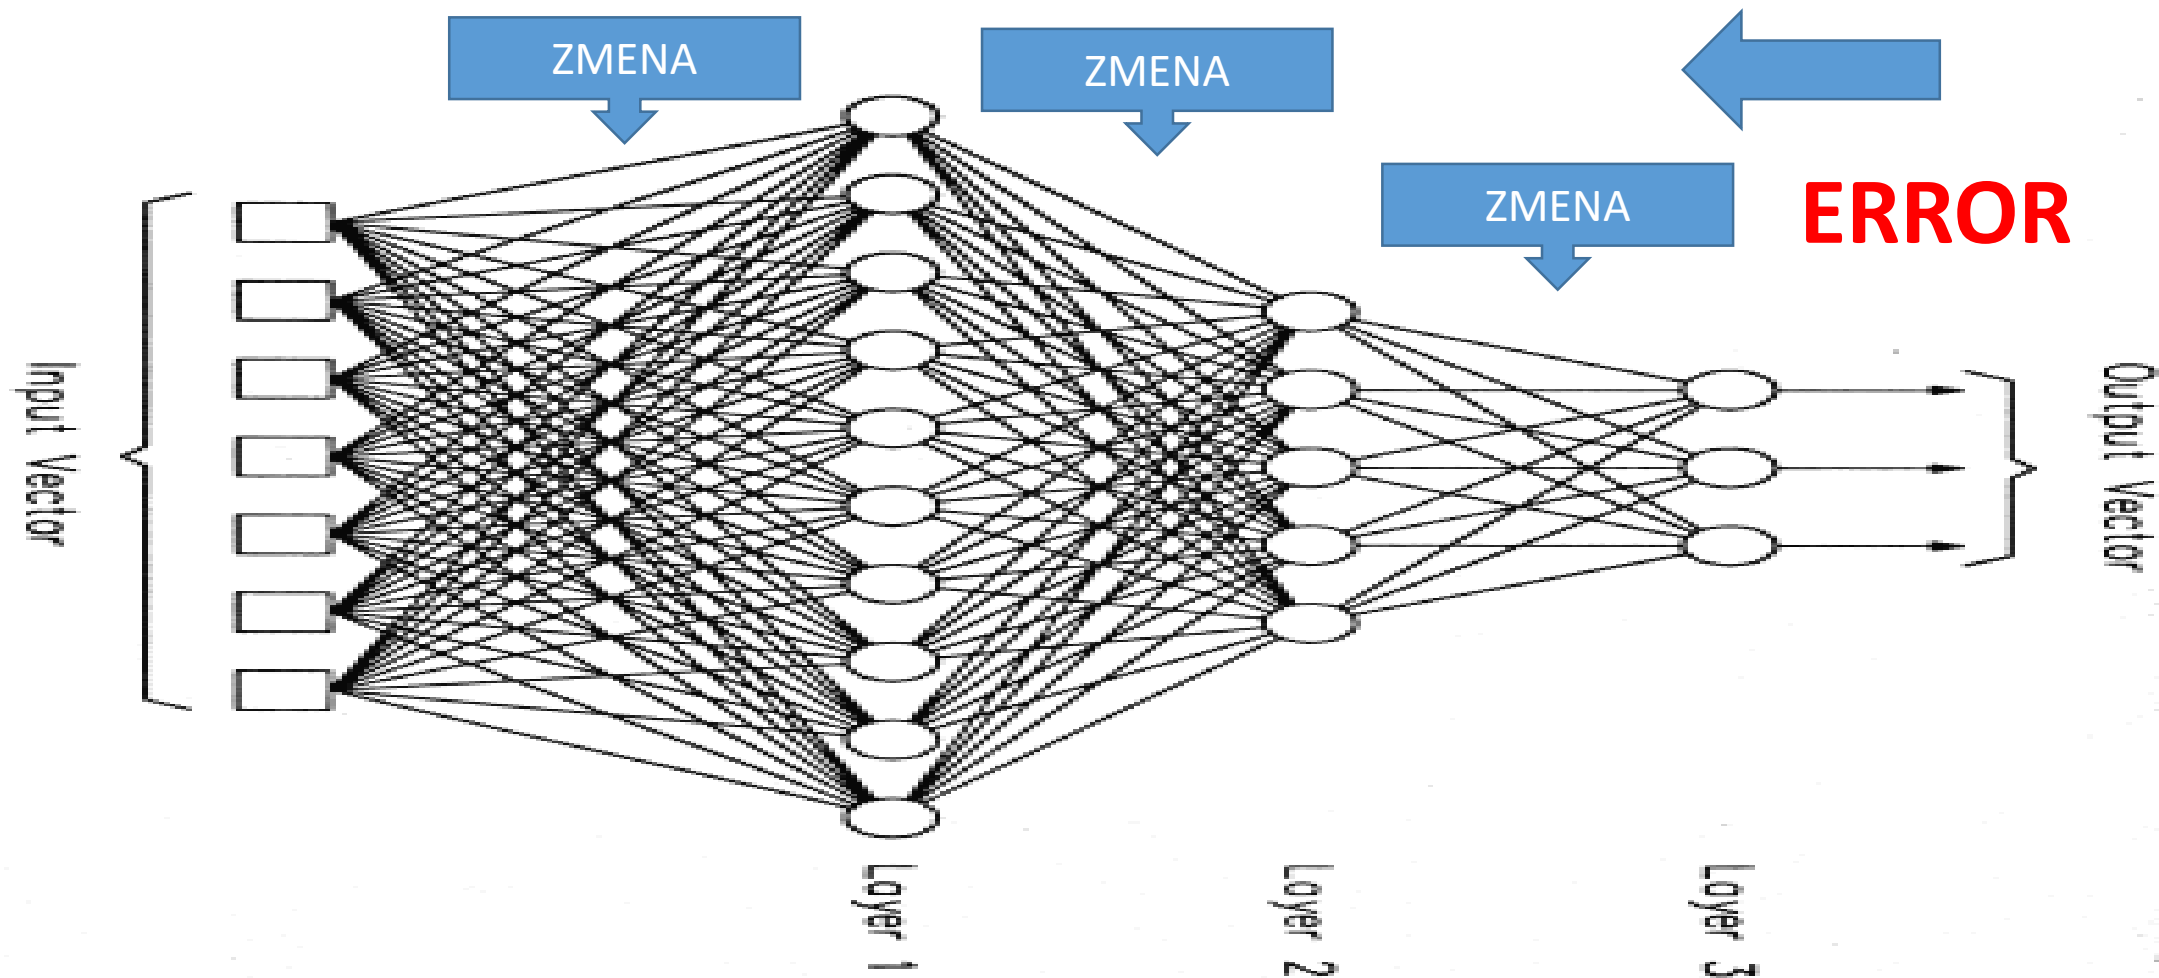
Základné princípy metódy spätného šírenia chyby



Čo vlastne robíme v príznačkovom priestore ???




Základné princípy metódy spätného šírenia chyby



Metóda Error Back Propagation ...

- Kontrolované učenie – AKO VYZERA TRÉNOVACIA MNOŽINA ???
- AKO MENIME Váhy M váh – zmena Váhy – závisí od Chyby E
- Chybový Priestor




Aké typy výpočtu chyby pozname ???

- Batch Learning
- In Line Learning

Univerzálna Aproximačná Teoréma

Predpoklad :

**Ak máme NS s min 1 a max. 2 skrytými vrstvami s sigmoidálnymi
Aktivačnými Funkciami v SIGMA Neurónoch**




**Potom takáto neurónová sieť
vie aproximovať ľubovoľnú všade differentovateľnú funkciu**

PROBLÉM – počet neurónov, počet vstiev (ale 2 stačia)

Pravidlá pri návrhu topológie :

- Počet neurónov v $L1 > L2 > L3$
- Doporučuje sa full prepojenie
- Doporučujú sigmoidálne neuróny
- Trénovacia množina dostatočne veľká versus Testovacia
- Problém preučenia neuronovej siete treba riešiť zmenou trénovaciej množiny



Samoštúdium


- <https://www.youtube.com/watch?v=bH6VnezBZfl>
- <https://www.youtube.com/watch?v=6RUwfKNdaV0&ebc=ANyPxKr55wGe5p5lcnCrzYD077Gu5Xz8luuwYP7FFX2MCYKecjmpT4CwqjuEj75VOBAB2kYtulYg9jNPNsNnUA1CmlpjLXN6Q>




QUESTION :

“Viete si predstaviť umelú
inteligenciu v odhaľovaní
potencionálnej korupcie ???

Reprezentácia znalostí z Dát v Sub-Symbolickom SU



Deep Learning neural network



Predspracovanie Dát – Príprava NOVÉHO Príznakového priestoru

Klasifikácia

prof. Fukushima

<https://www.youtube.com/watch?v=rp5p0Cy7ucE>

Samoštúdium

<https://www.youtube.com/watch?v=PlhFWT7vAEw>


(v 24 minute popisuje štrukturu Deep Learningu) ,,



QUESTION :

“Čo je to robot KIKI ??? ”

- https://www.youtube.com/watch?v=Wdrgi55O_hw
- <https://www.youtube.com/watch?v=K35HUaSTr3g>
- https://www.youtube.com/watch?v=Zsmzocmv_u0
- <https://www.youtube.com/watch?v=hYsJgmn6M18>



Cvičenia ---- výzva na bonusové body ...

